


Classificação de estresses bióticos em folhas de café utilizando visão computacional e aprendizado profundo



INSTITUTO
FEDERAL
São Paulo

Câmpus
São João da Boa Vista



Discente: Luís Henrique Vieira – BCC

Orientador: Gabriel Marcelino Alves

1

Contexto, Motivação e Objetivos



Contexto

- Café no Brasil:
 - Maior produtor e exportador do mundo;
 - 2º maior consumidor do mundo;
 - Estados com maior produção: Minas Gerais, Espírito Santo e São Paulo;

Figura 1 –Pé de café




Fonte: Elaborado pelo autor.



Estresses bióticos

- É o dano causado nas plantas por outros seres vivos;
- Os principais são:
 - Ferrugem;
 - Bicho mineiro;
 - Mancha de phoma;
 - Cercosporiose.
- Identificação a partir de coleta, separação e observação

Figura 2 - (a) bicho mineiro, (b) ferrugem, (c) mancha de phoma, (d) cercosporiose.



Fonte: Elaborado por Esgario, Krohling e Ventura (2020)



Motivação e Objetivos

- Motivação:
 - Apresentar um método de identificação de estresses bióticos no cafeeiro, com Inteligência Artificial.
- Objetivos:
 - Implementar redes neurais (CNN);
 - Aplicar e avaliar as redes;
 - Construir base de imagens adicional do leste paulista.

3


Aprendizado profundo



Aprendizado profundo

- O aprendizado profundo é uma sub-área do aprendizado de máquina;
- Permite a extração de características de dados brutos;

Figura 3 – Exemplo da extração de características.



Fonte: Elaborado por LeCun; Bengio; Hinton (2015)

5


Transferência de aprendizagem



Transferência de aprendizagem

- Transferência entre o domínio de origem e destino;
- Relaxa a necessidade de dados rotulados.

Figura 4 – Exemplos intuitivos de transferência de aprendizagem.



Fonte: (Zhuang et al., 2021)

4


Redes neurais convolucionais (CNN)



Rede neural convolucional

- Utilizada no reconhecimento de imagem e voz;
- Arquitetura composta pelas camadas:
 - Convolução;
 - Não linearidade;
 - Polling;
 - Totalmente conectadas.

Figura 5 – Exemplo da Arquitetura VGG16



Fonte: Elaborado por Bezdan e Džakula (2019).

5


Criação da base de imagens




Criação da base de imagens

- Estresses bióticos: Ferrugem e Cercosporiose;
- Total de Folhas: 264;
- Ferrugem (193), Cercosporiose (20) e Saudáveis (51);
- Coletadas:
 - Divinolândia;
 - São Sebastião da Grama;
 - Caconde;
 - Santo Antônio do Jardim.
- Não utilizada nas redes neurais

Figura 6 – Imagens da base do leste paulista



(a) Saudáveis



(b) Cercosporiose



(c) Ferrugem

Fonte: Elaborado pelo autor.

6

Desenvolvimento



Desenvolvimento da rede neural

- Utilização do conjunto Symptom da base de imagens BRACOL;
- Processo de *data augmentation*;
- Divisão do conjunto de treinamento (70%), validação (15%) e teste (15%);
- Arquiteturas desenvolvidas:
 - VGG16
 - ResNet50V2
 - MobileNetV2

Figura 7 – Código do método de criação das redes

```
def create_model(self) -> None:

    if self.architecture == Architecture.RESNET50V2:
        from keras.applications.resnet_v2 import ResNet50V2
        model_choose = ResNet50V2(include_top=False, weights='imagenet', input_shape=self.input_shape)

    elif self.architecture == Architecture.MOBILENETV2:
        from keras.applications.mobilenet_v2 import MobileNetV2
        model_choose = MobileNetV2(include_top=False, weights='imagenet', input_shape=self.input_shape)

    else:
        from keras.applications.vgg16 import VGG16
        model_choose = VGG16(include_top=False, weights='imagenet', input_shape=self.input_shape)

    if self.fine_tune > 0:
        for layer in model_choose.layers[:-self.fine_tune]:
            layer.trainable = False
    else:
        for layer in model_choose.layers:
            layer.trainable = True

    top_model = model_choose.output
    top_model = GlobalAveragePooling2D()(top_model)
    top_model = Dense(4096, activation='relu')(top_model)
    top_model = Dense(1072, activation='relu')(top_model)
    output_layer = Dense(self.n_classes, activation='softmax')(top_model)

    self.model = Model(inputs=model_choose.input, outputs=output_layer)

    self.model.compile(optimizer=self.optimizer, loss='categorical_crossentropy', metrics=['accuracy'])

    return self.model
```

Fonte: Elaborado pelo autor.

Figura 8 – Código de uso método de criação das redes

```
1 model_mobilenet = mobilenet.create_model()
2 model_mobilenet_fine_tune = mobilenet_fine_tune.create_model()
3
4 model_resnet = resnet.create_model()
5 model_resnet_fine_tune = resnet_fine_tune.create_model()
6
7 model_vgg = vgg.create_model()
8 model_vgg_fine_tune = vgg_fine_tune.create_model()
```

Fonte: Elaborado pelo autor.



Hiperparâmetros para treino

Tabela 1 - Hiperparâmetros utilizados

HiperParâmetro	Valor
Otimizador	Adam
Função de perda	Entropia cruzada
Tamanho do batch	32
Épocas	100
Taxa de aprendizagem	0,0001

Fonte: Elaborada pelo autor.

6

Resultados




Avaliação dos modelos

Tabela 2 - Resultados das métricas de avaliação

Arquitetura	Acurácia	Precisão	Recall
ResNet50V2	93,4%	93,4%	93,4%
VGG16	91,9%	92,1%	91,9%
MobileNetV2	89,9%	90,8%	89,9%


Fonte: Elaborado pelo autor.

Figura 9 - VGG16




Fonte: Elaborado pelo autor.

Figura 10 - VGG16 com ajuste fino




Fonte: Elaborado pelo autor.

Figura 11 - ResNet50V2




Fonte: Elaborado pelo autor.

Figura 12 - ResNet50V2 com ajuste fino




Fonte: Elaborado pelo autor.

Figura 13 - MobileNetV2



Fonte: Elaborado pelo autor.

Figura 14 - MobileNetV2 com ajuste fino



Fonte: Elaborado pelo autor.

7

Conclusões



Conclusões

- Alcançou seu objetivo ao identificar e classificar os estresses bióticos;
- ResNet50V2 apresentou os melhores resultados, com todas as camadas;
- A utilização das técnicas de transferência de aprendizagem melhorou os resultados;
- Iniciou-se a construção de uma base de dados do leste paulista.



Referências


AGRICULTURA, P. e. A. Ministério da. Café no Brasil. 2017. Disponível em: <<https://www.gov.br/agricultura/pt-br/assuntos/politica-agricola/cafe/cafeicultura-brasileira>>. 2, 3

Bezdan, T.; Džakula, N. B. Convolutional Neural Network Layers and Architectures. In: Proceedings of the International Scientific Conference – Sinteza 2019. Novi Sad, Serbia: Singidunum University, 2019. p. 445–451. ISBN 9788679127037. Disponível em: <<http://portal.sinteza.singidunum.ac.rs/paper/700>>. 7

ESGARIO, J. G.; KROHLING, R. A.; VENTURA, J. A. Deep learning for classification and severity estimation of coffee leaf biotic stress. Computers and Electronics in Agriculture, v. 169, p. 105162, 2020. ISSN 0168-1699. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0168169919313225>>. 2, 3, 4, 6, 7

LeCun, Y.; Bengio, Y.; Hinton, G. Deep learning. nature, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015. 5, 6

ZHUANG, F.; QI, Z.; DUAN, K.; XI, D.; ZHU, Y.; ZHU, H.; XIONG, H.; HE, Q. A comprehensive survey on transfer learning. Proceedings of the IEEE, v. 109, n. 1, p. 43–76, 2021. 5



Obrigado!

Perguntas?



E-mail: luis.hv2306@gmail.com